

Forward — Segmentação e Classificação de Churn da Rede Oficial Ford

Sprint 1 — Pipeline ML (Segmentação + Classificação + Calibração)

Autor: Lucca Saraiva Borges

Disciplina: Inteligência Artificial e Machine Learning — Prof. Carlos Fontoura (FIAP)

Data: 24/05/2026

Repositório: github.com/fwd-ford/forward-ml — branch sprint-1-ml-pipeline

Pipeline reprodutível de segmentação não-supervisionada (K-means, $k=4$) e classificação binária de churn (XGBoost two-stage com calibração estratificada) sobre o dataset oficial Ford Brasil — 175.552 VINs × 22 features comportamentais. Inclui documentação LGPD completa, model cards por modelo e análise de viés de seleção.

Sumário Executivo

Problema. A Ford Brasil precisa identificar quais clientes da rede oficial estão em risco de abandonar a manutenção autorizada (churn) para direcionar campanhas de retenção com ROI mensurável.

O dataset oficial fornecido pela coordenação FIAP contém **602.788 eventos de serviço** de **175.554 VINs únicos** ao longo de 2017–2026, sem rótulo de churn e sem qualquer feature socioeconômica.

Abordagem. Pipeline em três camadas:

- **Camada 1 — Segmentação K-means cega** sobre 11 features comportamentais → 4 personas com nomes de negócio (fiel, econômico, esquecido, abandono). Silhouette **0,40** (acima do piso 0,35 aceito para clustering comportamental).
- **Camada 2 — Classificação supervisionada** com target engenheirado (`churned = days_since_last_service > 365``, com `reference_date` fixa para reprodutibilidade) usando XGBoost two-stage + calibração isotônica estratificada por *scoring quality*. ****Acurácia balanceada 87,0%, F1 0,865, Brier 0,128****.
- **Camada 3 (opcional, Sprint 2)** — Análise de sobrevivência Kaplan-Meier por modelo × ano para projeção de curvas de retenção.

Principais resultados.

- O classificador final V3 atinge ROC-AUC **0,93** no dataset completo e **0,998** em cohorts maduras (2020–2022).
- Cohorts 2024–2025 têm ROC-AUC degradado por *right-censoring* (definição de churn de 365 dias não é observável em VINs jovens) — **limitação do target, não do modelo**.
- A persona abandono colide com `churned=1` em 99,98%, validação cruzada cega que confirma o alinhamento entre o classificador e o segmentador.
- O *cohort-aware sample weight* removeu o colapso do V2 em "detector da cohort 2020" e produziu métricas honestas em todos os anos de venda.

Limitação principal. O dataset só vê os ~5% da frota Ford que passou pela rede oficial. O modelo prediz churn *dentro da população visível*, não da frota total. Todo Model Card documenta esse viés explicitamente, conforme exigência do CLAUDE.md.

Próximos passos. Modelo paralelo de propensão (ADR-012), análise de sobrevivência com lifelines, deploy via FastAPI + scoring batch para Supabase (Sprint 2).

Contexto do dataset oficial

Fonte. `data/raw/vin_share_Desafio_02.xlsx`, entregue pela coordenação FIAP em 11/05/2026. Substituiu os datasets sintéticos de aquecimento (`ford_clientes_*.csv`) usados no início da sprint. Detalhes completos em `forward-docs/project/02e_DATASET_OFICIAL_E_FONTES.md`.

Forma. 602.788 linhas × 25 colunas. Granularidade: 1 linha = 1 evento de serviço. **175.554 VINs únicos**, 21 modelos, 435 dealers, model years 2017–2026, 100% Brasil.

Engenharia de features. O script `src/features.py` converte os eventos brutos em uma matriz `vin_features.csv` de 175k × 22 colunas, agregando por `VIN_Hash`. Regras críticas aplicadas:

- `km_max` truncado em 500.000 (raw chega a 955M, fisicamente impossível).
- `ServiceDate` parseada defensivamente em formato BR e US (mistos no mesmo coluna).
- `MainSource` com `.str.strip()` (duplicidade por whitespace).
- `VIN_Hash` (SHA1) tratado como **pseudonimização robusta**, não anonimização.
- `reference_date = max(ServiceDate) = 2026-05-04` (fixa, reproduzível — não usar `datetime.now()`).

Enriquecimento externo (em `data/external/`): FIPE values, dealers ABRADIF, recalls Senacon, cronogramas oficiais de manutenção. Usado para validação cruzada, não como feature direta (privacidade + governança).

Modelo 1 — Segmentação K-means

Identificação

- **Nome:** `kmeans_segmentation`
- **Data de treino:** 2026-05-24
- **Algoritmo:** `sklearn.cluster.KMeans (k=4, n_init=20, random_state=42)`
- **Tipo:** segmentação não supervisionada (clustering cego)
- **Artifact:** [data/models/kmeans_segmentation.joblib](#)
- **Profiles:** [data/models/kmeans_cluster_profiles.csv](#)
- **Métricas:** [data/models/kmeans_metrics.json](#)
- **Implementação:** [src/segmentation.py](#)
- **Notebook:** [notebooks/03_segmentation_kmeans.ipynb](#)

Objetivo

Agrupar os 175.552 VINs da rede oficial Ford em **personas comportamentais** com base em padrões de uso da rede (frequência, recência, dispersão entre dealers, dimensão da relação), permitindo:

- Desenhar estratégias de retenção diferenciadas por perfil (fiel × esquecido × abandono × econômico).
- Validar cruzadamente o classificador de churn — clusters com churn rate ≈ 1 (abandono) ou ≈ 0 (fiel) servem como sanity check independente.
- Fornecer um eixo de leitura humano para os scores do XGBoost (`churn_scorer_v3`), via SHAP médio por cluster.

Intended use & out-of-scope

Uso pretendido

- Insumo para campanhas de CRM segmentadas (uma mensagem por persona, não por score puro).
- Análise gerencial: "quantos clientes estão em risco de abandono", "qual o tamanho do segmento fiel".
- Validação cruzada do modelo supervisionado de churn (overlap de top-decile com cluster abandono).

Fora do escopo

- **Não substitui** o classificador para score individual — silhouette 0.40 indica grupos *moderadamente* separados, então cluster $\neq$ rótulo definitivo.
- **Não inferir socioeconômico, gênero, idade ou intenção de compra** a partir do cluster — features são puramente comportamentais.
- **Não usar como gatilho de decisão automatizada com efeito adverso** (negar garantia, recusar serviço): sempre como insumo a operador humano.

Training data

- **Fonte:** data/processed/vin_features.csv (gerado de data/raw/vin_share_Desafio_02.xlsx, dataset oficial Ford 2026-05-11).
- **Granularidade:** 1 linha por VIN_Hash. **175.552 VINs**.
- **Features usadas (11):** events_count, tenure_days, gap_avg_days, gap_last_days, days_since_last_service, dealers_distinct, primary_dealer_share, service_codes_distinct, km_per_month, is_loyal_to_dealer, is_single_event (vide KMEANS_FEATURES em [src/features.py](#)).
- **Pré-processamento:** StandardScaler (z-score) em todas as features — necessário porque K-means é sensível a escala (gap em dias vai a 1700; share em [0,1]).
- **NÃO usado:** model_name, model_year, vin_hash, churned (target supervisionado fica de fora — segmentação é cega).

Viés de seleção

- O dataset só vê **VINs que passaram pela rede oficial Ford pelo menos uma vez**. Os ~95% da frota Ford no Brasil que vão para oficinas independentes **não aparecem aqui** — qualquer afirmação sobre "fidelidade" se refere a *fidelidade visível na rede*, não fidelidade absoluta à marca.
- Distribuição enviesada por modelo: RANGER (56,7%) + KA (22,2%) dominam o dataset. Como a segmentação roda **sem** model_name, esse viés afeta os perfis indiretamente (RANGER tem padrão de manutenção pesado, KA tem padrão leve → influencia médias de km_per_month, events_count).
- Cohort effect: VINs vendidos em 2020 têm muito mais tempo de observação que VINs 2025 → naturalmente caem em clusters de gap alto. Mitigação: leitura dos perfis sempre cruzada com sales_year no relatório.

Evaluation

Escolha de k (sweep silhouette + inertia)

sweep_k em [src/segmentation.py:46](#) varre k=2..7 em sample de 10k para silhouette (full dataset para inertia). Decisão final: **k=4** — silhouette aceitável ($\geq 0,35$ por regra do CLAUDE.md), elbow visível e 4 personas mapeiam diretamente para a nomenclatura de negócio do DOC 00 (fiel/econômico/esquecido/abandono).

Métricas (k=4 no dataset completo)

Métrica	Valor
k	4
Silhouette (sample 10k)	0,4007
Inertia	773.615
n_samples	175.552

Silhouette $\geq 0,35$ é o piso aceitável para clustering comportamental (vide HANDOFF_ML.md). Comportamento humano não produz fronteiras tão limpas quanto dados sintéticos.

Perfis nomeados (heurística label-free, `_name_clusters` em `src/segmentation.py:62`)

Cluster	Nome	n	%	churn_rate	events	tenure_d	gap_last_d	dealers	dealer_share	single_event
0	econômico	30.252	17,2 %	10,7%	1,0	352	197	1,0	1,00	1,00
1	esquecido	44.286	25,2 %	58,5%	4,65	1.011	273	2,29	0,59	0,00
2	fiel	80.796	46,0 %	45,3%	4,29	862	235	1,04	0,99	0,00
3	abandono	20.218	11,5 %	99,98%	1,0	417	1.727	1,0	1,00	1,00

Cross-validações (sanity checks label-free)

1. **Cluster × MaintenanceNumber médio** — fiel e esquecido concentram revisões 4-5; abandono e econômico concentram revisão 1. ✓ esperado.
2. **Cluster × model_name** — fiel e econômico concentram RANGER (alta fidelidade da picape). abandono espalha entre KA, ECOSPORT, FIESTA (modelos descontinuados). ✓ consistente com retirada de portfólio.
3. **Cluster × churned** — abandono colide com churn=1 em 99,98% (era esperado: gap_last>365). fiel ainda assim tem 45% churn — alerta interno: parcela do "fiel" é fiel-histórico-mas-saiu.
4. **SHAP médio por cluster (validação cruzada com classificador V3, célula 16 do 04_classification.ipynb)**: abandono domina top features de risco; fiel domina top features de proteção. ✓ os dois modelos enxergam o mesmo fenômeno.

Persona naming methodology

A nomeação é **heurística determinística**, não LLM. Funciona em 3 etapas (vide `_name_clusters`):

1. abandono = $\text{argmax}(\text{rank}(\text{days_since_last_service}) + \text{rank}(\text{is_single_event}))$ — único + parado há muito tempo.
2. fiel = $\text{argmax}(\text{rank}(\text{events_count}) + \text{rank}(\text{primary_dealer_share}) - \text{rank}(\text{days_since_last_service}))$ **restrito a clusters multi-event** — alta frequência + concentrado num dealer + ativo. Restrição multi-event evita que single-event vire "fiel" trivialmente (dealer_share=1 com 1 visita não é fidelidade).
3. esquecido = restante com maior $\text{rank}(\text{days_since_last_service}) + \text{rank}(\text{gap_last_days})$ — múltiplos serviços mas drifting.
4. econômico = sobra.

Por que heurística e não rótulo manual: reprodutibilidade. Se rodar com k diferente ou em dataset futuro, os nomes recalibram sem revisão humana. O custo é que a nomenclatura pode escorregar em datasets muito diferentes — alerta de validação no notebook 03.

Limitations

Métricas

- **Silhouette 0,40** = grupos moderadamente separados, não perfeitamente. Esperar overlap nas fronteiras.
- **K-means assume clusters esféricos isotrópicos** — comportamento humano raramente é assim. DBSCAN/HDBSCAN não foram tentados (escopo Sprint 1).

Conceituais

- **Single-event domina 2 clusters** (econômico e abandono) — em datasets futuros com mais coverage isso pode mudar, e o número ótimo de k pode subir para 5-6.
- **Sem features financeiras** (valor do serviço, ticket médio) — econômico é nomeado por *padrão de uso leve*, não por ticket. Se ticket entrasse, parte do "fiel" viraria "premium".
- **Cohort confound**: VINs 2020 têm naturalmente mais eventos. A heurística parcialmente compensa (usa `gap_last_days` e `days_since`), mas resíduo existe.

Viés de seleção (repetido de Training Data)

- Apenas VINs visíveis na rede oficial — ~5% da frota Ford BR. **NÃO generaliza para "frota total Ford"**.
- VINs vendidos por concessionária mas que nunca voltaram para serviço **não existem no dataset**, então o segmento "comprou e sumiu de cara" é invisível.

Estabilidade

- `random_state=42` fixo em treino — resultados reproduzíveis. Mas KMeans é sensível a init: rodar em outro dataset (mesmo gerado pelo mesmo schema) pode produzir cluster ids permutados — confiar nos **nomes**, não nos ids numéricos.

LGPD — proteção de dados

A segmentação processa as mesmas features comportamentais agregadas do classificador. Esta seção é resumida — a versão completa está em [MODEL_CARD_CLASSIFIER.md](#) e aplica-se integralmente aqui.

Pontos específicos do segmentador

- **Base legal**: legítimo interesse (art. 7, IX) — finalidade idêntica à do classificador (retenção pós-venda).
- **Finalidade**: desenho de campanhas segmentadas, não tomada de decisão individual. **Cluster sozinho NÃO pode ser usado para decisão automatizada com efeito jurídico (art. 20)**.
- **Pseudonimização**: VIN_Hash (SHA1) não entra no clustering — é dropado antes do StandardScaler. O artefato `kmeans_segmentation.joblib` contém apenas centroides e scaler, **não armazena nenhum VIN**.
- **Retenção**: mesmo critério do classificador (12 meses ou até retreino). Cluster atribuído por VIN é regenerável sob demanda.
- **Direitos do titular**: atendidos pelo mesmo procedimento `anonymize_customer()` da forward-infra migration 013 — apagar o VIN da tabela `vin_features` automaticamente impede que o cluster seja

recalculado para esse titular.

- **Inferência de atributos sensíveis:** o cluster econômico poderia, em uso indevido, ser proxy para perfil socioeconômico. **Vedado** o cruzamento do cluster com campanhas de crédito/seguro/preço.
- **Risco residual de re-identificação:** centroides + perfis (n=20k+) não permitem identificar indivíduo. Risco real surge ao cruzar `vin_clusters.csv` (que tem `vin_hash`) com tabelas externas — proibido contratualmente.

Versionamento & retreino

- **Versionamento:** artefatos em `data/models/kmeans_segmentation.joblib`. Próximas versões: anexar suffix (`kmeans_segmentation_vN.joblib`).
- **Frequência de retreino:** alinhada ao classificador (a cada 3 meses ou quando drift em `events_count` médio > 10%).
- **Monitorar:** distribuição de tamanho dos 4 clusters (se abandono cresce > 15% sem mudança no modelo, é drift real do negócio, não bug). Silhouette score em retreino — alerta se cair abaixo de 0,30.

Referências

- [HANDOFF_ML.md](#) — seção 4 (estratégia de segmentação)
- [CLAUDE.md](#) — regras críticas (silhouette $\geq 0,35$, nomes de negócio)
- [forward-docs/project/02e_DATASET_OFICIAL_E_FONTES.md](#) — contexto do dataset oficial
- [MODEL_CARD_CLASSIFIER.md](#) — model card do classificador supervisionado (par)

Modelo 2 — Classificador Churn V3

Identificação

- **Nome:** churn_scorer_v3
- **Data de treino:** 2026-05-24
- **Algoritmo principal:** XGBoost 2.0 (GPU, device="cuda")
- **Arquitetura:** Two-stage classifier + stratified isotonic calibration
- **Artifact:** [data/models/churn_scorer_v3.joblib](#)
- **Inferência:** [src/inference.py](#) → `ChurnScorer.load().predict(df)`

Objetivo

Para cada VIN da rede oficial Ford no Brasil, calcular a **probabilidade de churn** (deixar de usar a rede oficial), de modo calibrado e auditável, para uso em campanhas de retenção.

Target engenheirado

```
churned = (reference_date - last_service_date).days > 365
# reference_date = 2026-05-04 (max ServiceDate, fixo p/ reprodutibilidade)
```

Arquitetura V3 — 4 melhorias sobre o V2

1. Cohort-aware sample weights ([features.py:175](#))

```
weight = (1 / freq[model_name]) * (1 / freq[sales_year])
# normalized to mean = 1
```

Compensa **dois vieses simultâneos**: dominância de RANGER/KA por modelo + dominância de cohort 2020 (92% churn) por idade. Sem isso, o modelo colapsa em "detector de 2020".

2. Two-stage classifier ([inference.py:188](#))

- **Stage 1:** Roteador determinístico classifica cada VIN como high_confidence (multi-event, treinável), single_event (só 1 visita) ou holdout (tenure < 365d).
- **Stage 2A:** Modelo `model_multi` treinado em 117k multi-event VINs (com Optuna params).
- **Stage 2B:** Modelo `model_single` treinado SOMENTE em single-event VINs (27k VINs com a mesma config).
- VINs holdout usam `model_multi` mas com calibração específica.

3. Stratified isotonic calibration ([inference.py:230](#))

3 calibradores **separados**, treinados na população onde cada um se aplica:

- `cal_hc` → para `high_confidence` (na val temporal multi-event)
- `cal_se` → para `single_event` (no próprio subset)
- `cal_holdout` ← compartilha com `hc`

Resolve o problema do V2 onde `single-event` ficava +15pp **over-confident** e holdout +48pp.

4. Per-quality F1-optimal thresholds

Quality	Threshold ótimo
<code>high_confidence</code>	0.319
<code>single_event</code>	0.750
<code>holdout</code>	0.319 (mesma do <code>hc</code>)

Métricas — V3 no dataset completo (175.552 VINs)

Métricas globais

Métrica	Valor
Acurácia	87.01%
Acurácia balanceada	86.97%
Precision	88.12%
Recall	84.93%
F1	0.8649
ROC-AUC	0.9262
PR-AUC	0.9304
Brier (calibração)	0.1275

Por scoring_quality

Quality	n	acc	balanced_acc	F1	ROC-AUC	Brier
single_event	26.982	99.20%	99.28%	0.993	0.998	0.007
holdout	31.938	90.03%	88.95%	0.864	0.908	0.086
high_confidence	116.632	83.36%	83.38%	0.832	0.907	0.167

Por cohort de venda

Ano	n	Churn real	Score médio	ROC-AUC	Balanced acc
2020	64.634	92.7%	0.680	0.998	95.7%
2021	18.960	75.7%	0.456	0.998	90.2%
2022	12.137	43.2%	0.177	0.994	84.1%
2023	21.094	21.4%	0.144	0.903	74.8%
2024	37.029	5.2%	0.183	0.656	55.2%
2025	21.568	0.04%	0.180	0.310 ■■	45.1%
2026	130	0.8%	0.173	0.996	99.6%

■■ Cohorts 2024–2025 (right-censoring): VINs novos não tiveram tempo de churnar pela definição de 365d, ROC-AUC fica abaixo de random. **Isso é limitação do target, não do modelo.**

Evolução V1 → V2 → V3

Métrica	V1 baseline	V2 Optuna	V3 (atual)
Acurácia	73.0%	73.0%	87.0%
Acurácia balanceada	73.1%	73.1%	87.0%
F1	0.733	0.733	0.865
Brier	0.023 (in-sample)	0.310	0.128
Features	19 (com leak)	22 (sem leak)	22 + cohort weights
Calibração	Não	Isotônica única	Estratificada (3 calibradores)
Arquitetura	1 modelo	1 modelo	2 modelos (two-stage)
Validação	Random split	Temporal 3-way	Temporal 3-way

Hiperparâmetros (Optuna 40 trials, TPE)

```
{
  "max_depth": 9,
  "learning_rate": 0.01535,
  "subsample": 0.7731,
  "colsample_bytree": 0.6201,
  "min_child_weight": 9,
  "reg_alpha": 0.1164,
  "reg_lambda": 0.3685,
  "gamma": 1.4852,
  "n_estimators": 2500,           # com early_stopping_rounds=60
  "tree_method": "hist",
  "device": "cuda",
}
```

Features (22, ENRICHED_FEATURES)

Core comportamentais (12): events_count, tenure_days, km_max, km_per_month, dealers_distinct, primary_dealer_share, service_codes_distinct, service_types_distinct, is_loyal_to_dealer, is_single_event, model_year, model_name_freq.

Cohort & sazonalidade (7, novas V2): sales_year, sales_month, sales_quarter, years_since_sale, age_when_first_serviced_days, first_service_month, sale_year_minus_model_year.

Gap shape (3, novas V2): gap_range_ratio, gap_skew, services_per_year.

Removidas vs V1: gap_avg/min/max/last/last_vs_avg, age_at_last_service_days, is_warranty_active — todas com leak via imputação ou via last_service_date.

Limitações honestas

Right-censoring por design do target

- Cohort 2024-2025 tem pouquíssimos VINs com churn observável (matemática, não modelo).
- A acurácia global de 87% **inclui as cohorts antigas** onde basicamente tudo já churnou — modelo identifica corretamente.
- Em produção, **não usar o score pra VINs com sales_date < 12 meses** sem regras complementares.

Métricas são pós-treino em todo o dataset

- O treino do model_multi foi feito com split temporal honesto; mas o scoring final aplica em 175k VINs (incluindo as próprias amostras de treino do model_single e do recalibrador).
- A acurácia 87% global é **honesto-mas-otimista**. A acurácia balanceada em **cohort 2024** (55%) é o piso real de generalização.

Viés de seleção

- Dataset só vê VINs que passaram pela rede oficial pelo menos 1 vez. **Os 95% da frota Ford que vão pra independente NÃO estão aqui.**
- Não generaliza pra "frota total Ford".

LGPD — Proteção de dados pessoais

O modelo processa identificadores veiculares pseudonimizados e features comportamentais derivadas de eventos de serviço. Esta seção documenta o tratamento conforme Lei 13.709/2018 (LGPD).

Base legal (art. 7)

- **Hipótese aplicada:** legítimo interesse (art. 7, IX) — retenção pós-venda na rede oficial Ford, com benefício direto para o titular (lembretes de manutenção, ofertas personalizadas, segurança veicular via recall).
- **Teste de proporcionalidade:** finalidade legítima ✓, necessidade (não há substituto menos invasivo do que features agregadas) ✓, balanceamento (titular tem direito ao opt-out via anonymize_customer() — vide forward-infra migration 013) ✓.

- **NÃO aplicável:** consentimento explícito (não foi coletado pelo desafio acadêmico) e execução de contrato (modelo não é cláusula contratual).

Finalidade (art. 6, I — adequação)

- **Única finalidade declarada:** estimar `churn_probability` por VIN para campanhas de retenção (CRM, ofertas de revisão, agendamento proativo).
- **Vedado:** uso para precificação de seguro, scoring de crédito, transferência a terceiros não-Ford, ou enriquecimento de cadastro fora do escopo pós-venda.

Dados tratados (art. 5, I e II)

- **Pseudonimização (art. 13, IV):** `VIN_Hash = SHA1(VIN)`. Em 5M tentativas de reversão dirigida, 0 colisões/recoveries (vide `forward-infra/SECURITY.md`, `STRIDE-S2`). Considera-se **pseudonimização robusta, não anonimização** — re-identificação continua tecnicamente possível mediante cruzamento autorizado com tabela mestre (que NÃO está neste repositório).
- **Features comportamentais (22):** contagens e médias agregadas — `events_count`, `tenure_days`, `km_per_month`, `dealers_distinct`, `primary_dealer_share`, etc. Nenhuma feature identifica diretamente o titular.
- **Dados removidos por design:** nome, CPF, telefone, endereço, e-mail, CEP, gênero, renda — nada disso entra no pipeline (não existe no dataset oficial v2).
- **NÃO há dados sensíveis (art. 11):** sem origem racial, religião, saúde, biometria, sindical, política.

Retenção (art. 16)

- **Artefato do modelo** (`churn_scorer_v3.joblib`, ~25 MB): retenção de 12 meses ou até retreino subsequente (a cada 3 meses por governança). Versões antigas (v1, v2) podem ser preservadas em arquivo morto para auditoria, sem reuso operacional.
- **Scores produzidos** (`client_scores` em Supabase): retenção alinhada à política de CRM da Ford — recomendação: 24 meses, com purge automático via job agendado.
- **Features intermediárias** (`vin_features.csv`): regeneráveis on-demand a partir dos eventos brutos — não há motivo para reter por mais de 30 dias após o treino.
- **Dataset bruto** (`vin_share_Desafio_02.xlsx`): sob custódia da coordenação FIAP; este repositório não redistribui.

Direitos do titular (art. 18)

- **Confirmação e acesso (art. 18, I e II):** atendidos via endpoint `GET /clientes/{vin}/scores` (`forward-api-java`), que retorna o último score do VIN e a versão do modelo.
- **Correção (art. 18, III):** se eventos de serviço estiverem incorretos, a correção é feita no sistema-fonte (DMS dealer); o próximo retreino propaga.
- **Anonimização/eliminação (art. 18, IV e VI):** procedimento operacional via `anonymize_customer(vin_hash)` em `forward-infra/migrations/013_anonymize_customer.sql` — apaga o registro do titular em todas as tabelas e re-hash o VIN com salt rotacionado, tornando o histórico no modelo permanentemente desvinculado.
- **Portabilidade (art. 18, V):** features agregadas exportáveis em CSV mediante solicitação ao DPO.
- **Revisão de decisão automatizada (art. 20):** este modelo **não toma decisão isolada com efeitos jurídicos relevantes** — saída é insumo para campanha de marketing/retenção, sempre revisada por operador humano antes de contato com o cliente. Ainda assim, garante-se direito a explicação via

SHAP values disponíveis por VIN.

Transferência internacional (art. 33)

- **Treino:** 100% local (GPU CUDA on-premise / workstation do desenvolvedor, Brasil). Sem transferência internacional durante a fase de modelagem.
- **Inferência:** prevista em infraestrutura nacional (Supabase região São Paulo conforme [forward-infra/README.md](#)). Caso futura migração para cloud em outra região seja avaliada, exigir **DPIA específica** e cláusulas-padrão de transferência internacional.

Encarregado / DPO

- **Encarregado pelo tratamento (art. 41):** Lucca Saraiva Borges (webbersaraivaborges@gmail.com) — interlocutor do projeto acadêmico com a ANPD e titulares.
- Em deploy real Ford, este papel migraria para o DPO corporativo Ford Brasil.

Riscos residuais

- **Re-identificação por cross-reference:** mesmo com VIN pseudonimizado, cruzamento com FENABRAVE (emplacamentos), FIPE (valores), DETRAN (proprietário) **poderia** desanonimizar. Cláusula contratual com qualquer integrador externo deve proibir esse cruzamento.
- **Inferência de atributos sensíveis:** `model_name` + `dealer_state` podem servir de proxy para perfil socioeconômico. Mitigação: não usar o score para decisões com impacto adverso (negação de crédito, seguro, garantia).
- **Vazamento do artefato joblib:** o modelo serializado **não contém PII**, mas contém os feature splits do XGBoost que poderiam, em ataque inverso, ajudar a inferir distribuição de comportamento da base. Mitigação: storage em bucket privado com IAM restrito, sem URL pública.
- **Pseudonimização não é anonimização (parecer ANPD 2022):** este repositório trata `VIN_Hash` como **dado pessoal** para todos os efeitos da LGPD, mesmo após hash.

Referências cruzadas

- [forward-infra/SECURITY.md](#) — STRIDE completo, threat S2 (spoofing por VIN reversal)
- [forward-infra/migrations/013_anonymize_customer.sql](#) — implementação do direito de exclusão
- [LGPD art. 7](#) (bases legais), [art. 18](#) (direitos do titular), [art. 50](#) (boas práticas)

Como usar (deploy)

Python (Java backend chama via Python ou via API FastAPI):

```
from src.inference import ChurnScorer
scorer = ChurnScorer.load()
df_features = ... # mesmo schema de vin_features.csv
scored = scorer.predict(df_features)
# colunas adicionadas:
#   churn_probability (calibrado)
#   churn_probability_raw (sem calibração)
#   churn_predicted (0/1 no threshold por quality)
#   churn_risk_tier (very_low / low / high / very_high)
#   churn_decile (D1 = top 10% arriscados)
#   score_fidelidade (1 - churn_probability)
#   scoring_quality (high_confidence / single_event / holdout)
```

Pipeline end-to-end:

```
python -m src.classification          # treina V1 baseline (referência)
python -m scripts.tune_optuna         # otimiza V2 (40 trials)
python -m src.inference               # treina V3 (two-stage + calibração)
python -m scripts.score_final         # produz CSV final + métricas + análise de erro
pytest tests/ -v                      # valida pipeline
```

Governança & retreino

- **Frequência:** retreinar a cada 3 meses ou quando drift em positive rate > 5pp.
- **Monitorar:** distribuição de days_since_last_service, ROC-AUC por model_name, calibração por cohort.
- **Versionamento:** artifact em data/models/churn_scorer_vN.joblib (N incremental).

Análise por decil operacional (resumo)

Métricas globais (175k VINs)

- **n**: 175552
- **churn_real**: 0.4898
- **accuracy**: 0.8701
- **balanced_accuracy**: 0.8697
- **precision**: 0.8812
- **recall**: 0.8493
- **f1**: 0.8649
- **roc_auc**: 0.9262
- **pr_auc**: 0.9304
- **brier**: 0.1275

Métricas por scoring_quality

Quality	n	acc	balanced_acc	F1	ROC-AUC	Brier
high_confidence	116,632	0.834	0.834	0.832	0.907	0.167
holdout	31,938	0.900	0.889	0.864	0.908	0.086
single_event	26,982	0.992	0.993	0.993	0.998	0.007

Métricas por cohort de venda

Ano	n	churn_real	score	ROC-AUC	balanced_acc
2020	64,634	0.927	0.680	0.9979	0.957
2021	18,960	0.757	0.456	0.9981	0.902
2022	12,137	0.432	0.177	0.9936	0.841
2023	21,094	0.214	0.144	0.9026	0.748
2024	37,029	0.052	0.183	0.6555	0.552
2025	21,568	0.000	0.180	0.3098	0.451
2026	130	0.008	0.173	0.9961	0.996

Resumo dos erros (top 5 modelos com pior acc)

Modelo	n	Acc	%FP	%FN
TRANSIT	4,120	0.788	0.087	0.125
TERRITORY	11,376	0.801	0.135	0.065
RANGER	78,225	0.809	0.092	0.100
F-150	1,681	0.857	0.113	0.030
BRONCO SPORT	5,689	0.872	0.038	0.090

Conclusões e roadmap Sprint 2

Status Sprint 1.

- Pipeline reprodutível com `load_features()` → `segmentation.fit()` → `ChurnScorer.train()` → `score_final`.
- Dois modelos com Model Card completo (LGPD, viés, limitações documentadas).
- Notebooks acadêmicos em `notebooks/` para os 4 estágios (EDA, segmentação, classificação, leak audit).
- Anti-data-leakage auditado em `05_leak_audit.ipynb` — features pós-evento foram removidas do conjunto final V3.
- Calibração estratificada por *scoring quality* — resolveu over-confidence de +15pp (single-event) e +48pp (holdout) do V2.

Roadmap Sprint 2.

- Survival analysis** (Kaplan-Meier) por `model_name` × `model_year` com `lifelines` — projeção de curvas de retenção complementar ao classificador binário.
- Modelo paralelo de propensão** sobre o subset sintético antigo (ADR-012) — comparativo metodológico para o relatório acadêmico.
- API FastAPI** com `POST /predict`, `POST /simulate`, `GET /health` — desacoplar o Java backend do `joblib` direto.
- Scoring batch** para Supabase via cron (1×/dia) — escrever em `client_scores` consumido pelo CRM Ford.
- Monitoramento de drift**: alertar quando `positive_rate` se mover > 5pp ou silhouette do segmentador cair < 0,30 no retreino.

Riscos abertos.

- Cohort 2024–2025 sem rótulo confiável (right-censoring) — usar score *com cautela*, idealmente combinar com regra de negócio ("se `sales_date` < 12 meses, suprimir").
- Modelo treina em dataset filtrado (`tenure_days` ≥ 365) mas scoring final aplica em todos — métricas globais são *honestas-mas-otimistas*. O piso real está nos 55% de balanced accuracy em cohort 2024.
- Dataset cobre apenas a rede oficial — modelos NÃO devem ser usados para inferir comportamento da frota total Ford.

Apêndice A — Figuras




Figura A1 — SHAP beeswarm (V3 sem single-event).




Figura A2 — SHAP bar plot (importância média absoluta).




Figura A3 — Curvas ROC / PR / Calibração (V3).




Figura A4 — Métricas por grupo (modelo × cohort).




Figura A5 — Auditoria anti-data-leakage (comparativo V1 → V3).